

Performance Evaluation of Tensorflow Parallel Strategies for Deep Learning Training on HPC Clusters

Kenichi Brumati, Marcelo Cardoso Oliveira Gulart, Rayan Raddatz de Matos

Recapitulação

Custom Training Loop

Reproducibilidade e Ambiente de Testes

Projeto Experimental

Resultados

Modelo Linear

Conclusão

Recapitulação

Mudanças desde a última etapa

- Focamos apenas no TensorFlow

Mudanças desde a última etapa

- Focamos apenas no TensorFlow
- Adicionamos outro modelo menor (EfficientNetB0)

Mudanças desde a última etapa

- Focamos apenas no TensorFlow
- Adicionamos outro modelo menor (EfficientNetB0)
- Focamos em entender o tempo de treino e descartamos métricas secundárias

Mudanças desde a última etapa

- Focamos apenas no TensorFlow
- Adicionamos outro modelo menor (EfficientNetB0)
- Focamos em entender o tempo de treino e descartamos métricas secundárias
- Mudamos o dataset para o TinyImageNet-200

Mudanças desde a última etapa

- Focamos apenas no TensorFlow
- Adicionamos outro modelo menor (EfficientNetB0)
- Focamos em entender o tempo de treino e descartamos métricas secundárias
- Mudamos o dataset para o TinyImageNet-200
- Mudamos o hardware (downgrade)

<colocar grafico antigo aqui>

- Degradação de performance (aumento do tempo por época) ao adicionar novos workers.

- O treinamento distribuído síncrono exige que todos os nós atualizem os pesos simultaneamente.
- A operação de AllReduce (soma de gradientes) trafega dados pela rede a cada batch, assim, a latência de comunicação superou o ganho do paralelismo

Custom Training Loop

- Utilização de um Custom Training Loop.

- Implementação de acumulação de gradientes.
- Sincronização a cada 4 batches.

- Aumenta o batch size efetivo antes de disparar a sincronização.
- Melhora a razão Computação/Comunicação, reduzindo o tráfego de rede e destravando o escalonamento.

Reproducibilidade e Ambiente de Testes

- A base oficial distribui estritamente Software Livre.
- Incompatibilidade com drivers proprietários essenciais (NVIDIA CUDA Toolkit e cuDNN).

- Impossibilidade de adicionar canais não-oficiais (nonguix) no ambiente PCAD.

- Uso de **Python Virtual Environment** (venv).
- Isolamento de versões via pip garante reprodutibilidade sem violar restrições de licenciamento de drivers de GPU.

Anteriormente estávamos utilizando máquinas da partição Tupi, por razões de **alta concorrência** mudamos para a partição Poti.

- Hardware anterior: Intel(R) Core(TM) i9-14900KF e **NVIDIA GeForce RTX 4090**
- Hardware UTILIZADO: Intel(R) Core(TM) i7-14700KF e **NVIDIA GeForce RTX 4070**

Tivemos alguns problemas como a configuração da rede da **poti4** e quedas repentinas da **poti2** que atrasaram os experimentos.

Projeto Experimental

Executamos dois tipos de treinamento:

- "sync" -> Sincronismo total com `model.fit()`
- "ctl" -> Sincronismo a cada 4 batches com Custom Training Loop


Escolhemos além do **ResNet50** com ~**25.6M** parâmetros um modelo menor: **EfficientNetB0** com ~**5.3M** parâmetros.

- **Batch size:** 32, 64, 100
- **Quantidade de nodos:** 1, 2 e 3


- $2 \times 2 \times 3 \times 3 = \mathbf{36}$ configurações
- Cada uma foi **replicada 5 vezes**.
- Total de **180** execuções!

Resultados


Resultados por batch



Resultados por número de nodos




Aglomerado final dos dados




Modelo Linear

Nosso modelo linear



Nosso modelo quadrático



Conclusão

- O tamanho do modelo assim como a rede é um fator crítico para o treino distribuído síncrono.
- Mesmo com uma rede de baixo throughput é possível obter ganhos através de uma boa configuração do ambiente e do modelo.

Prever o overhead de comunicação baseado no tamanho do modelo e das condições da rede.

Perguntas?

